PTBD - Python w zastosowaniach Big Data

***Kierunek*:**
Zarządanie informacją

Prowadzący: Pavlo Melnyk

Zasady zaliczenia i kontakt

- ***Forma zaliczenia*: własny projekt + obrona na ostatnich zajęciach**
- ***Dop. liczba nieobecności (bez względu na powód)*: 2**

Statystyka to fundament na którym wyrosły ML oraz AI

Statystyka to dyscyplina naukowa badająca zmienność zjawisk i generujące ją procesy losowe, zgodnie z prawami prawdopodobieństwa. Termin ten pochodzi z łaciny: statisticus, „polityczny, dot. polityki”, od status, „państwo, stan” – nawiązując do jego początków jako narzędzia do analizy danych państwowych.

Statystyka: Projektant rzeczywistości

Czym jest Statystyka?

To nauka o:

- Uczeniu się z danych.
- Podejmowaniu decyzji w warunkach niepewności.

Pomaga odróżnić sygnał od szumu.

Statystyka jako starożytny fundament, na którym stoi nowoczesny gmach AI

Nowoczesne ML i AI (ChatGPT, systemy rekomendacyjne, autonomiczne samochody) są jak drapacz chmur – imponujący, szklany, nowoczesny.

Jednak jego fundamenty są starożytne. To statystyka, która rozwija się od wieków. Kto nie zrozumie dobrze fundamentów, nie zbuduje stabilnej kariery w ML oraz AI.

Podstawowe pojęcia

Populacja vs. Próbka

***Populacja*:** cała grupa, która nas interesuje (np. wszyscy Polacy).
***Próbka*:** reprezentatywny fragment (np. 1000 losowo wybranych Polaków).
***Cel*:** na podstawie próbki wnioskować o populacji.

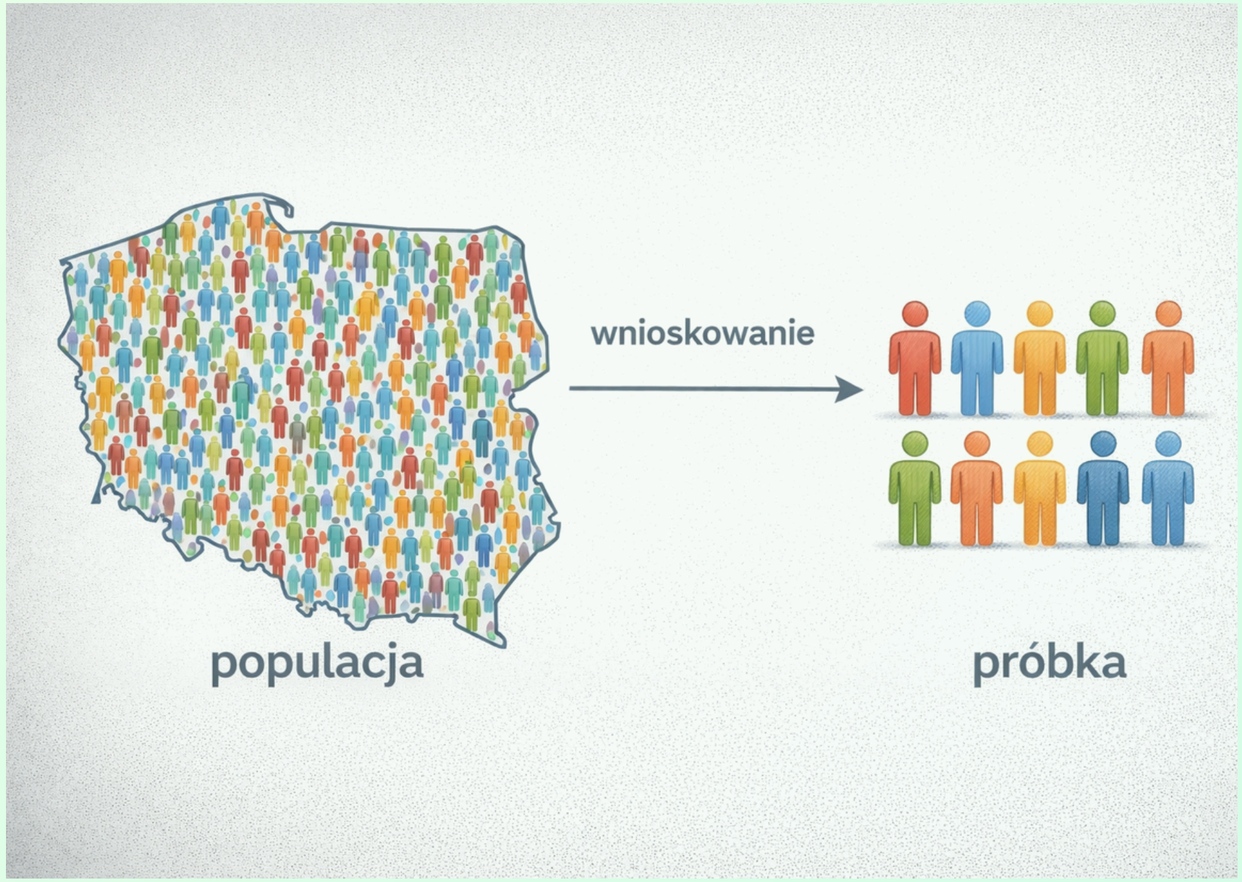

Przykład: Sondaże

Przykład: 1000 losowo wybranych respondentów (reprezentatywnych ze względu na wiek, płeć, miejsce zamieszkania).

Jak to działa w praktyce?

- Ankieterzy dzwonią/pytają 1000 osób (próbka).
- Okazuje się, że **420** z nich (**42%**) zamierza głosować na Partię A.
- Wniosek (estymacja): Badacze publikują wynik: **"Partia A może liczyć na 42% poparcia w całym kraju"** (populacja).

- Zastrzeżenie: Ponieważ to tylko próbka, wynik obarczony jest margin of error (np. +/- 3%). Oznacza to, że realny wynik w populacji prawdopodobnie znajdzie się w przedziale 39-45%.

Kluczowy wniosek: Dobrze dobrana próbka (reprezentatywna) pozwala nam z dużą dokładnością poznać prawdę o całej populacji.

Dla dużych prób **Margin of error =** $\frac{100\%}{\sqrt{n}}$

Świat opisują zmienne

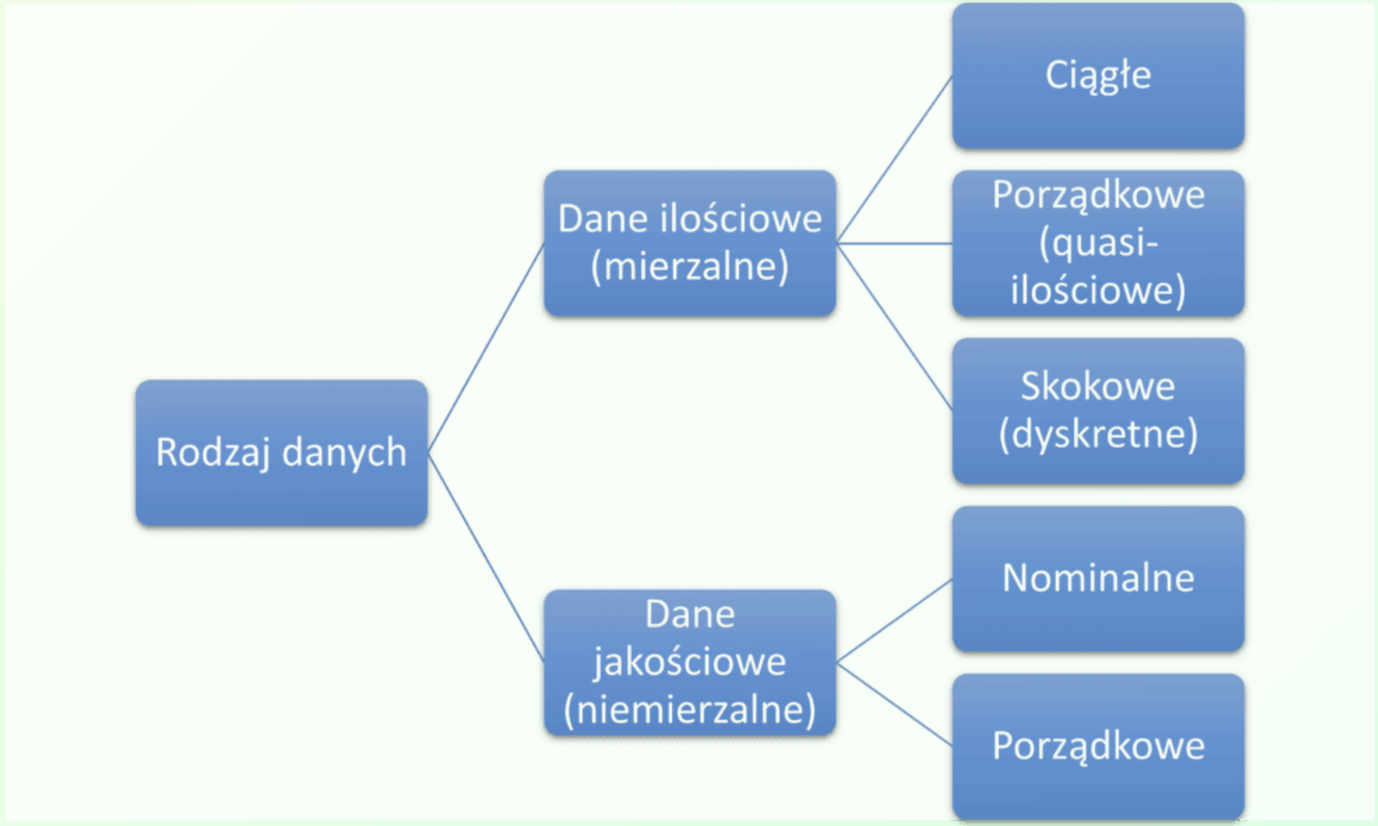

- **Ilościowe (Liczbowe):** Można liczyć i mierzyć.
  - Ciągłe: Wzrost, waga, czas.
  - Dyskretne: Liczba dzieci, liczba samochodów.
- **Jakościowe (Kategoryczne):** Opisują przynależność.
  - Nominalne (bez hierarchii): Płeć, kolor oczu.
  - Porządkowe (z hierarchią): Wykształcenie, oceny szkolne.

Wykresy

Wykresy pokazują wartości zmiennych w określonym kontekście: w czasie, porownaniu czy agregacji

Jak wybrać wykres?

- Masz dane w czasie? **Wykres liniowy.**
- Chcesz porównać "coś" do "czegoś"? **Wykres słupkowy.**
- Chcesz pokazać % całości? **Wykres kołowy (ale tylko dla 2-3 składników).**
- Chcesz pokazać, że "więcej X = więcej Y"? **Wykres punktowy.**
- Chcesz pokazać, jak dane są rozrzucone? **Histogram lub Box plot.**

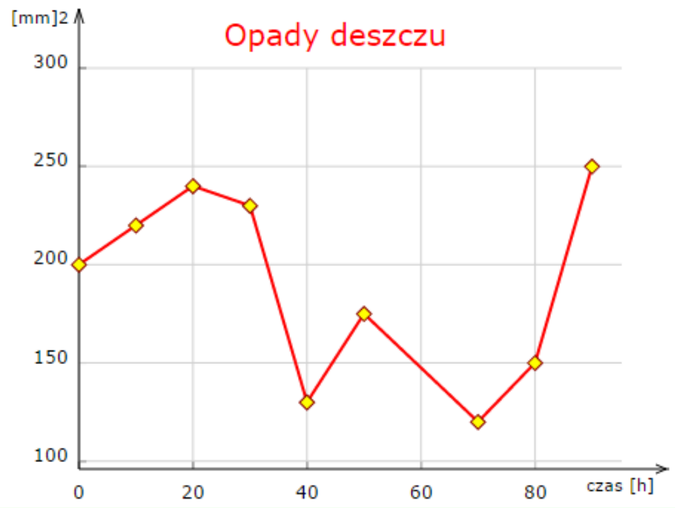
Opady deszczu
[mm]2
300
250
200
150
100
0
20
40
60
80
czas [h]

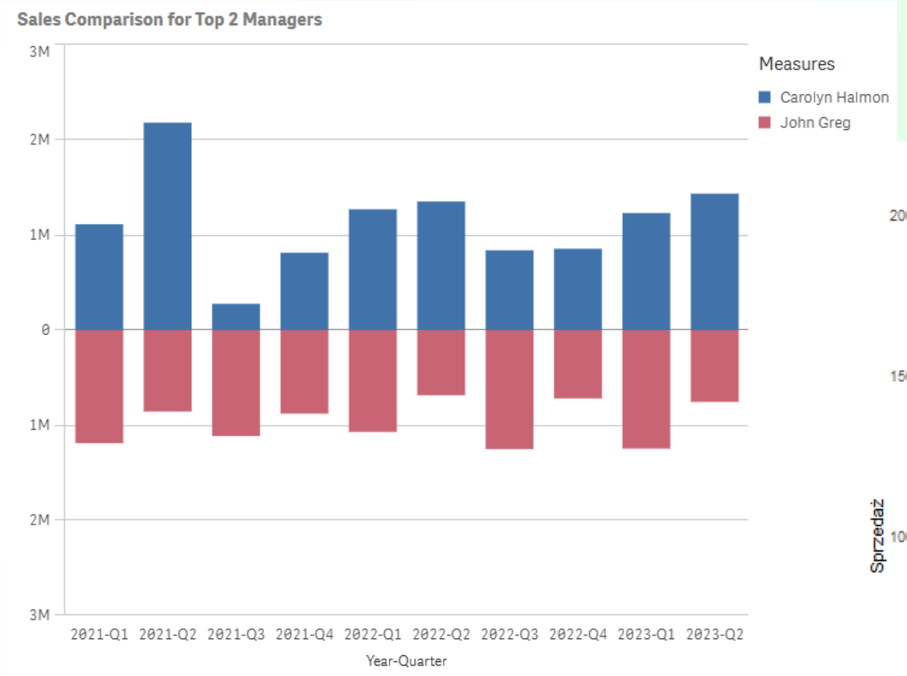
Sales Comparison for Top 2 Managers
Measures
Carolyn Halmon
John Greg
3M
2M
1M
0
1M
2M
3M
2021-Q1
2021-Q2
2021-Q3
2021-Q4
2022-Q1
2022-Q2
2022-Q3
2022-Q4
2023-Q1
2023-Q2
Year-Quarter

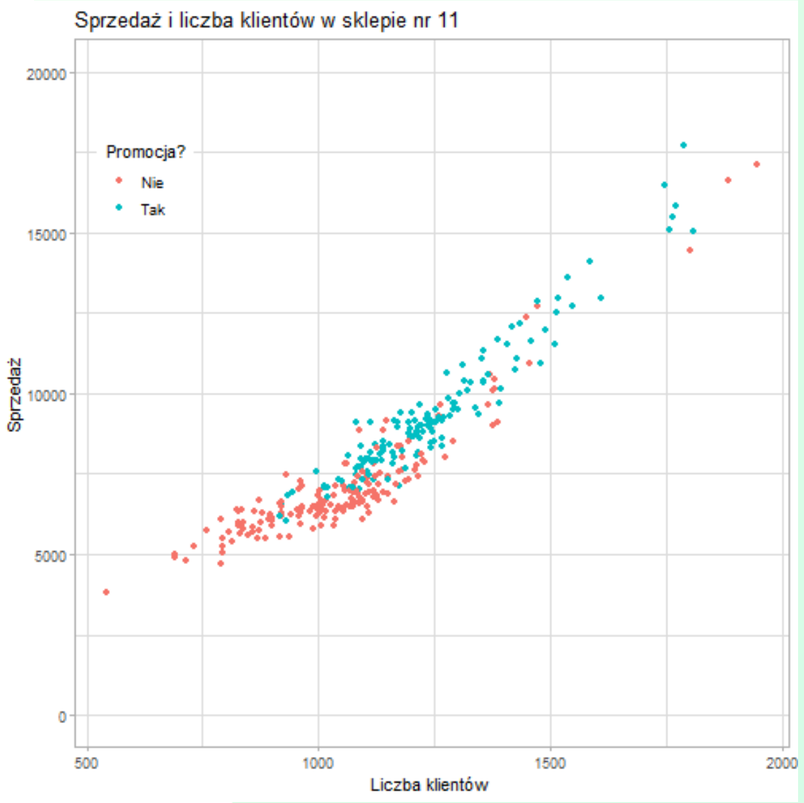
Sprzedaż i liczba klientów w sklepie nr 11
Promocja?
Nie
Tak
Sprzedaż
20000
15000
10000
5000
0
500
1000
1500
2000
Liczba klientów

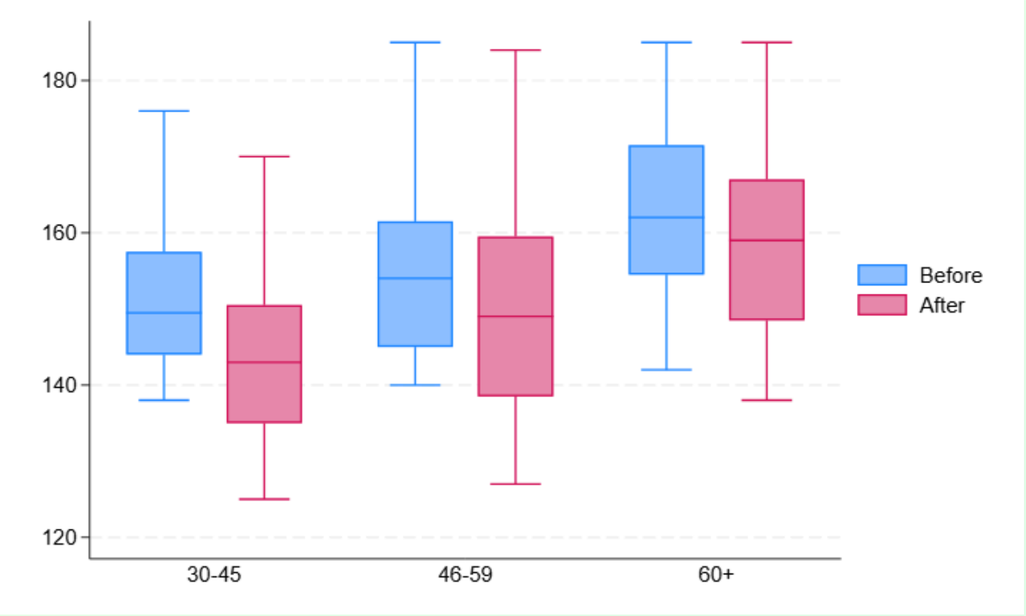
180
160
140
120
30-45
46-59
60+
Before
After

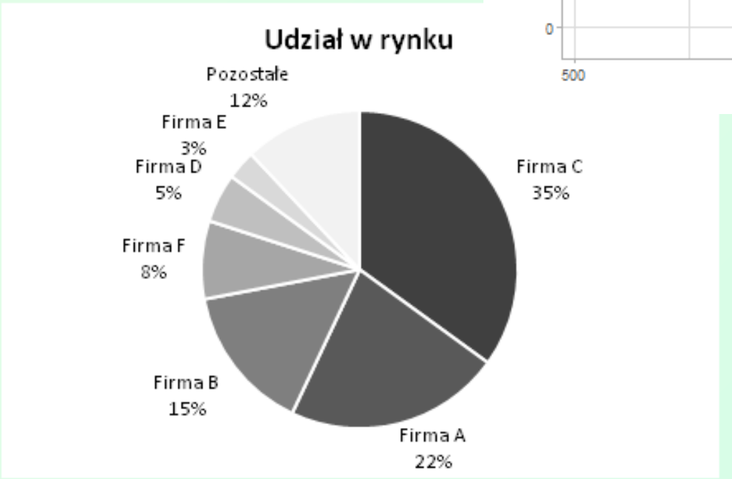
Udział w rynku
Pozostałe
12%
Firma E
3%
Firma D
5%
Firma C
35%
Firma F
8%
Firma B
15%
Firma A
22%

Korelacja a przyczynowość (causality)

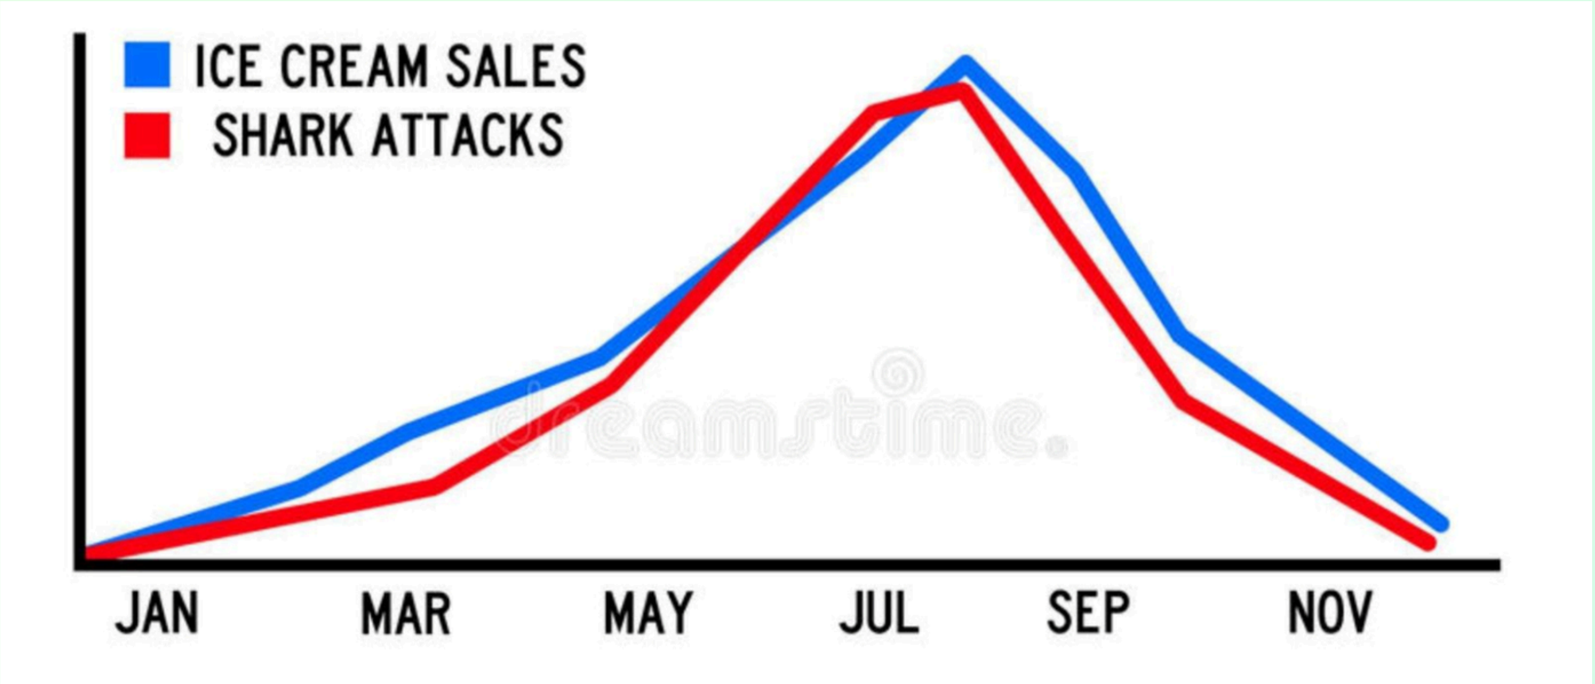

Source: https://www.kdnuggets.com/2019/09/risk-ai-big-data.html

Czym jest p-value?

Cel: Zrozumienie, czy zaobserwowany efekt jest rzeczywisty, czy to tylko przypadek.

Wartość p (p-value): Prawdopodobieństwo, że wyniki wystąpiły przypadkowo.

Przykład medyczny (Badanie leku)

- Sytuacja: Testujemy nowy lek na ból głowy.
- Hipoteza zerowa (H_0): "Nowy lek działa tak samo jak placebo (nie działa lepiej)."
- Wynik: Po podaniu leku 90% pacjentów wyzdrowiało (w grupie placebo 50%).
- Obliczone p-value = 0.03

Interpretacja wyników:

- Zakładając, że lek nie działa (czyli H_0 jest prawdą), istnieje tylko 3% szans (p=0.03), że wyniki pacjentów byłyby aż tak dobre (lub lepsze) jak zaobserwowane, gdybyśmy powtórzyli badanie wiele razy.
- Wniosek: 3% to mało (mniej niż 5%). Odrzucamy hipotezę zerową. Lek działa.

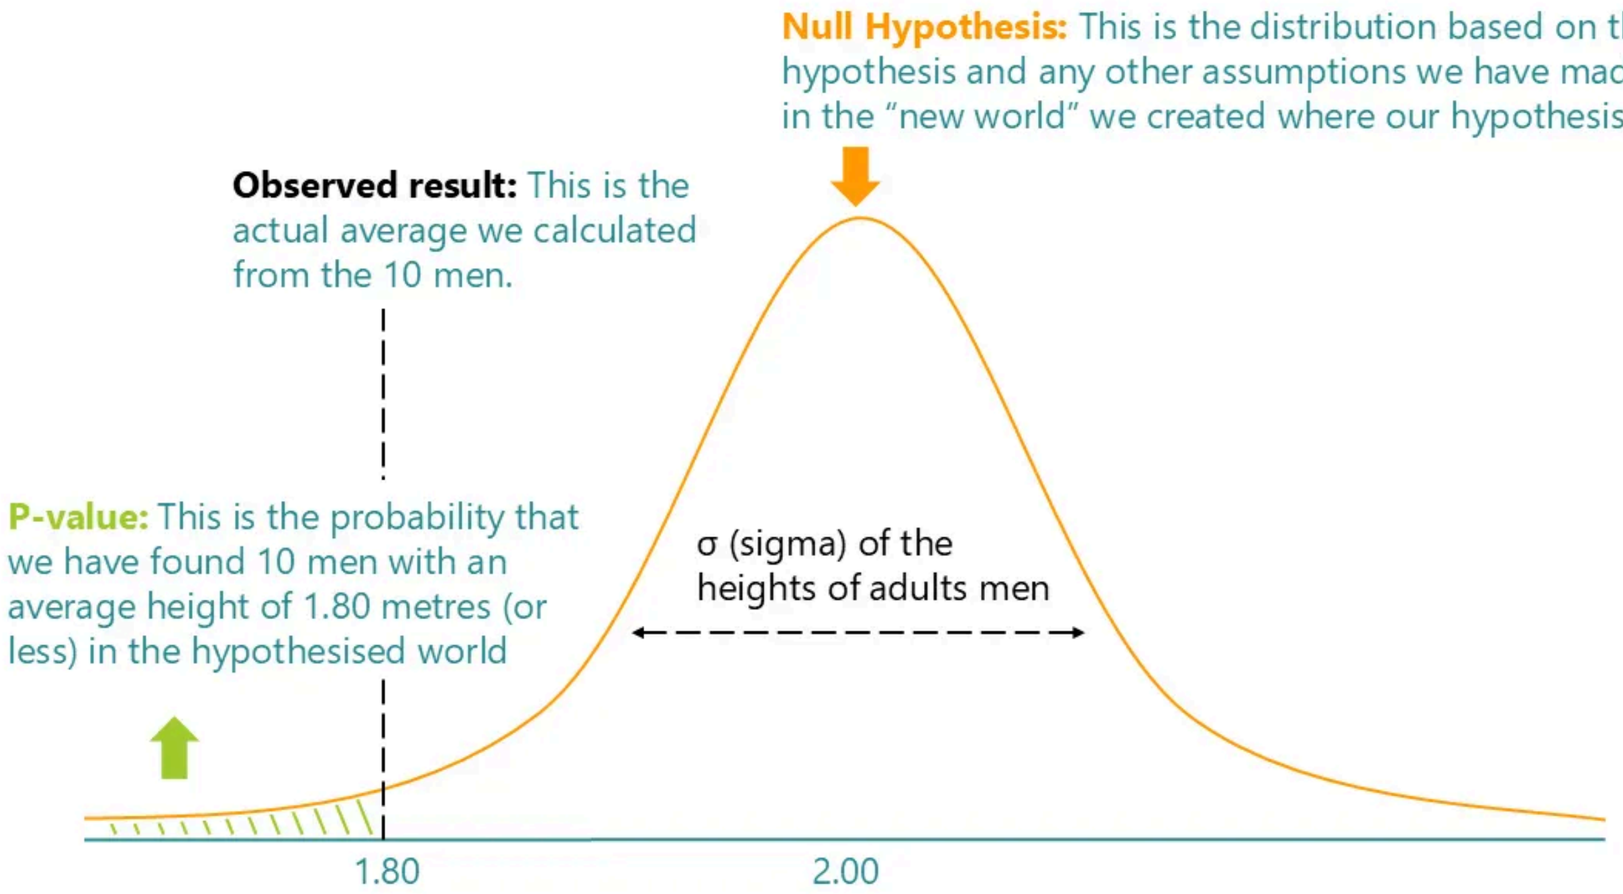

źródło: https://medium.com/@silvio.saglimbeni/lets-finally-understand-p-value-and-what-it-is-not-49b455f39a96

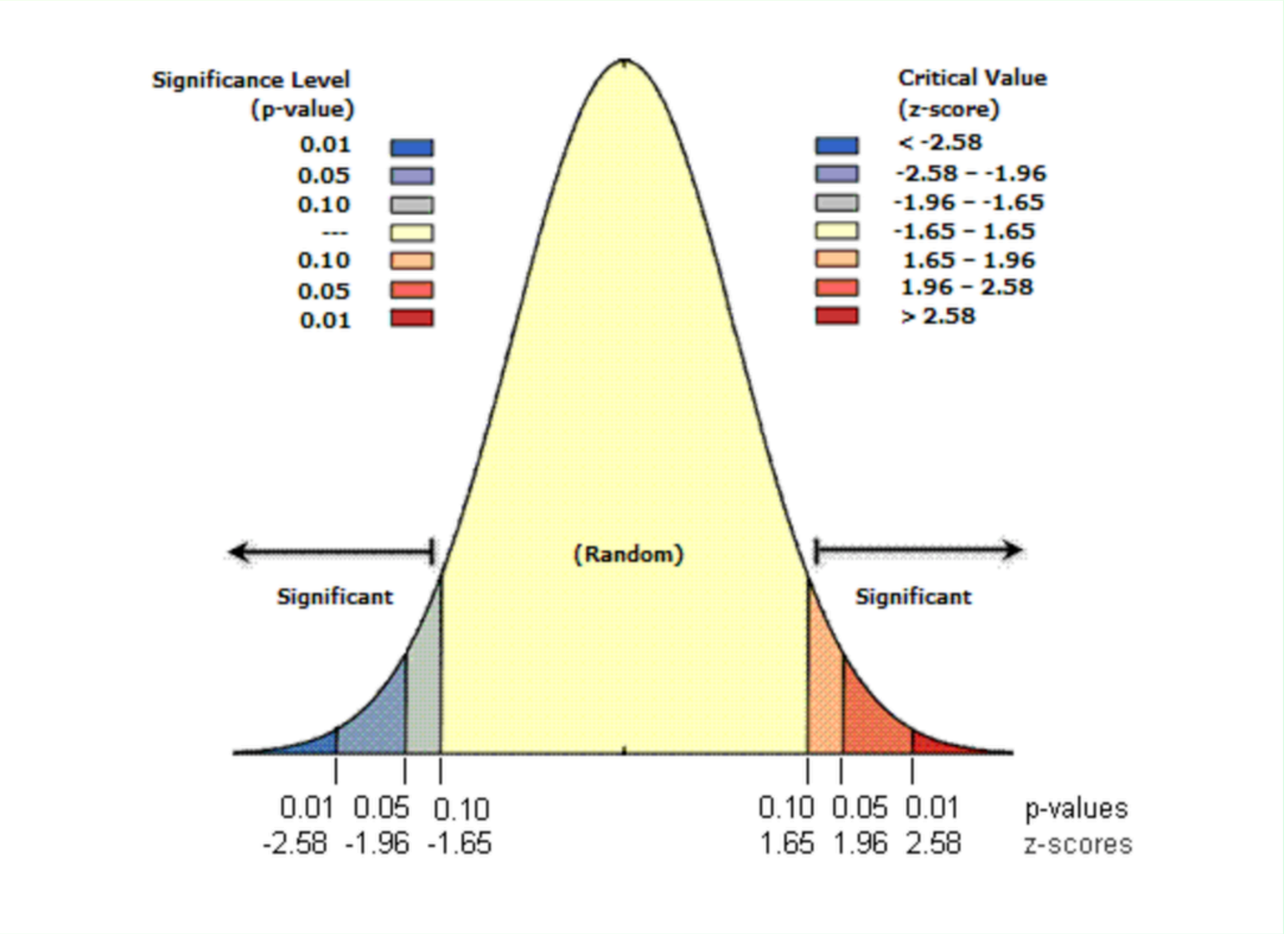

Source: https://desktop.arcgis.com/

Z-score (wskaźnik standaryzowany) to po prostu odpowiedź na pytanie: "Jak bardzo nietypowy jest ten wynik na tle reszty?"

Mówiąc wprost: Z-score mówi Ci, o ile "długości kroków" (odchyleń standardowych) oddaliłeś się od środka stada (średniej).

Banki i karty kredytowe uwielbiają Z-score.

- System monitoruje, ile zwykle wydaje osoba (średnia) i jak bardzo zmieniają się jej wydatki (odchylenie).
- Normalnie wydaje ok. 200 zł dziennie (odchylenie = 50 zł).
- **Nagle robisz zakupy za 500 zł.**
  - **Z-score = (500-200)/50 = 6.0.**
  - **Reakcja banku: "Coś tu nie gra! To zdarzenie jest oddalone o 6 kroków od normy!". Blokada transakcji i SMS z pytaniem: "Czy to na pewno Ty?". Im wyższy Z-score (w wartości bezwzględnej), tym większe podejrzenie, że dzieje się coś nietypowego (oszustwo).**

Średnia,
Mediana,
Dominanta (Moda),
Zakres

Miary Tendencji Centralnej

- **Średnia**: suma wartości / liczba.
  - Wada: Wrażliwa na wartości odstające (np. pensja prezesa zawyża średnią pensję w firmie).
- **Mediana**: wartość środkowa po posortowaniu.
  - Zaleta: Odporna na wartości odstające. Mówi o "przeciętnym" Kowalskim.
- **Dominanta (Moda)**: Najczęstsza wartość.
  - Przykład: Najpopularniejszy rozmiar buta w sklepie.
- **Zakres**: wartość bezwzględna różnicy między największym a najmniejszym elementem

Maths Angel

Mean, Median, Mode & Range

Mean

$$\frac{\text{Sum of all values}}{\text{Total number of values}}$$

$$\frac{5+7+6+3+5}{5} = 5.2$$

Median

The value in the middle after sorting

3 5 **5** 6 7

Mode

The value that occurs most often

5

Range

max - min

7 - 3 **= 4**

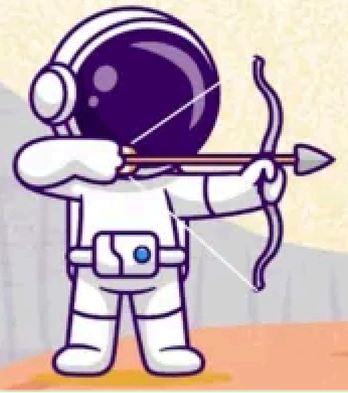

Odchylenie standardowe,
Wariancja,
Współczynnik zmienności,
Odchylenie ćwiartkowe

Miary Rozproszenia

- **Odchylenie standardowe:**
  - najpopularniejsza miara określająca średnie zróżnicowanie wyników od średniej arytmetycznej. Im mniejsza wartość, tym bardziej spójne dane.
- **Wariancja:**
  - średni kwadrat odchyleń poszczególnych wartości od średniej arytmetycznej. Podkreśla duże różnice w danych.
- **Współczynnik zmienności:**
  - relatywna miara rozproszenia, uniezależniona od jednostek miary, obliczana jako iloraz odchylenia standardowego i średniej
- **Odchylenie ćwiartkowe**:
  - oparte na kwartylach, mierzy rozproszenie wokół mediany.

Miary rozproszenia – Zwarte czy rozrzucone?

Małe odchylenie standardowe

Klasa A: wszyscy mają 3 (wartości skupione)

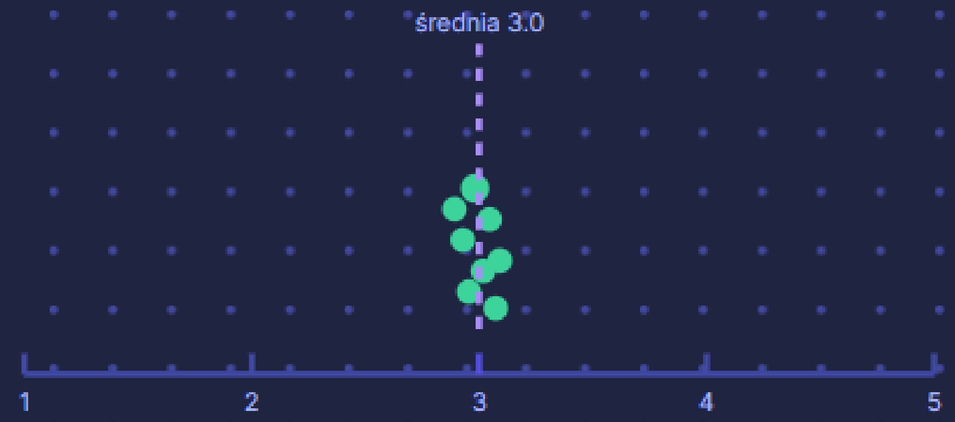

Duże odchylenie standardowe

Klasa B: połowa 1, połowa 5 (wartości rozrzucone)

Odchylenie standardowe: miara tego, jak bardzo wartości różnią się od średniej.

Ta sama średnia 3.0, kompletnie inna rzeczywistość!

Prawo Wielkich Liczb (PWL)

10 rzutów

70% orłów (duża zmienność)

1000 rzutów

51% orłów (bliżej 50%)

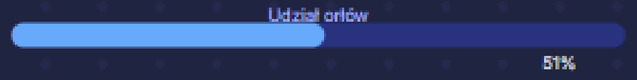

1 000 000 rzutów

50,1% orłów (bardzo blisko 50%)

↓

PRAWDA: 50%

Im więcej prób, tym bliżej prawdy.

Podsumowanie – Co naprawdę daje statystyka?

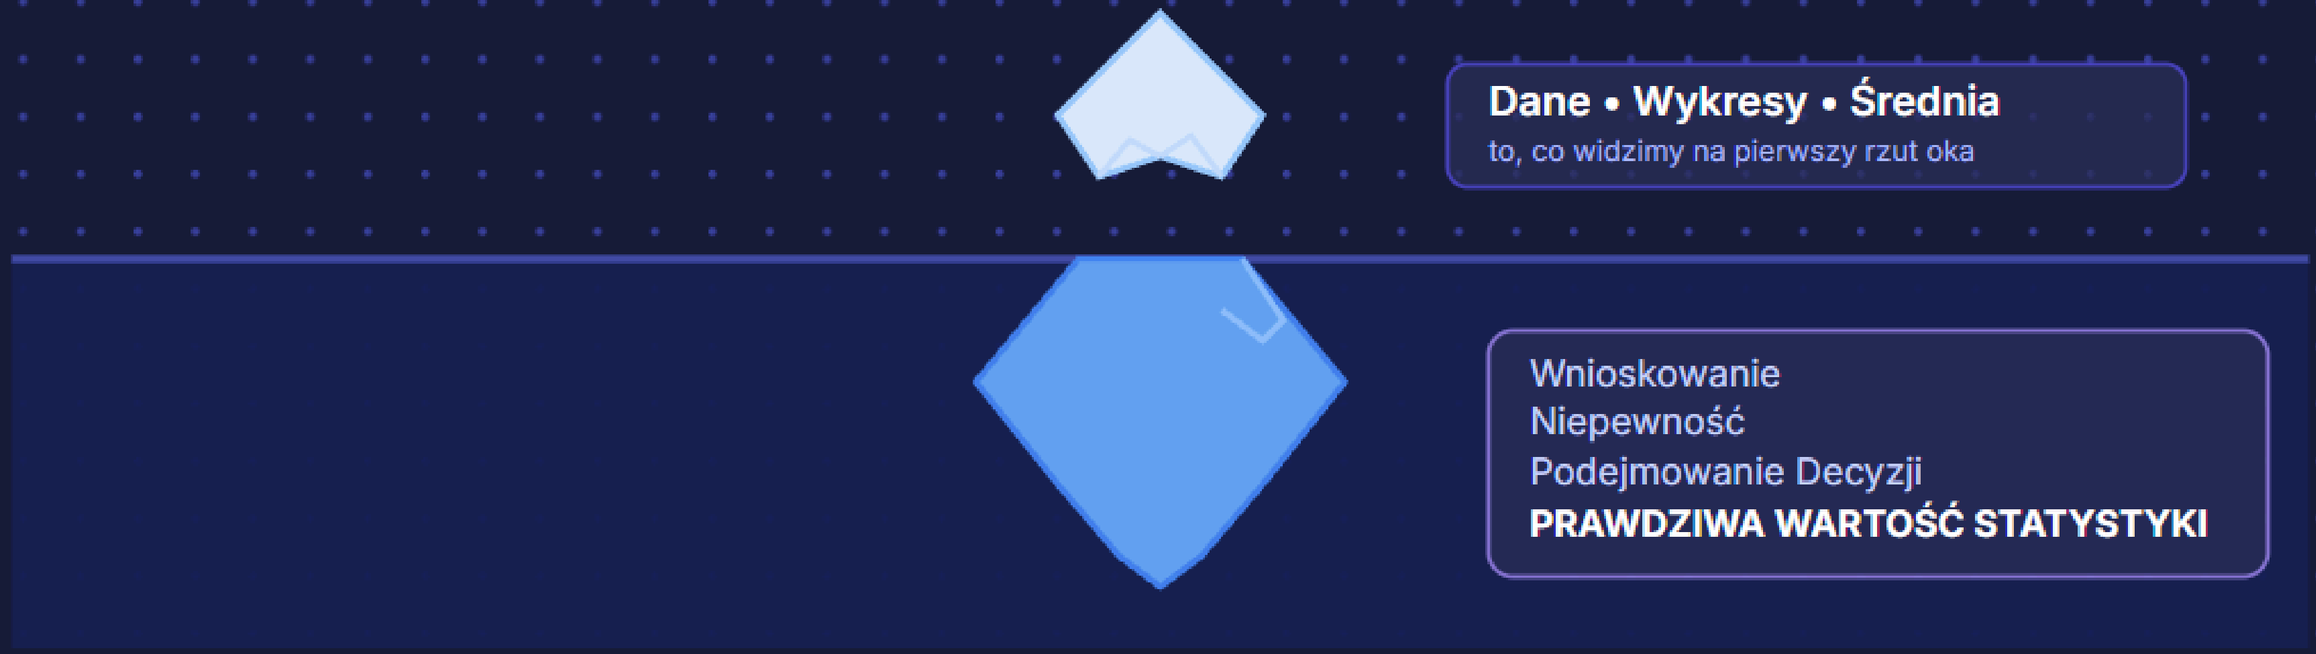

Dane • Wykresy • Średnia
to, co widzimy na pierwszy rzut oka

Wnioskowanie
Niepewność
Podejmowanie Decyzji
PRAWDZIWA WARTOŚĆ STATYSTYKI

Radzenie sobie z niepewnością

Wyciąganie mądrych wniosków

Fundament pod uczenie maszynowe

Dyskusja

- **Pytanie 1: Prawo wielkich liczb w życiu**

"Ktoś kiedyś powiedział: “*ten lekarz ma 20 lat doświadczenia, więc mu ufam?* Albo że “ten polityk rządzi od 10 lat, więc wie, co robi”? Czy to jest przejaw Prawa Wielkich Liczb, czy raczej pułapka?"

- **Pytanie 2: Pułapka średniej**

"Wyobraźcie sobie, że wchodzicie do baru, w którym jest 5 informatyków i 1 bezdomny. Średnia wartość portfela w tym barze wynosi 10 000 zł. Czy to znaczy, że jesteś w bezpiecznej, bogatej okolicy? Czy czułbyś się komfortowo, zostawiając swój portfel na stole?"

- **Pytanie 3: Reprezentatywność próbki**

"Sondaż wyborczy przeprowadzono na grupie 1000 osób, dzwoniąc na numery stacjonarne w godzinach 10:00-16:00. Wynik: partia X ma 60% poparcia. Czy ufacie temu wynikowi? Kogo ten sondaż nie uwzględnił?"

Big Data: Paliwo dla nowoczesnej statystyki, ML i AI

Big data

- **Definicja:** Big data to nie tylko "dużo danych". To dane, których nie da się efektywnie przetwarzać tradycyjnymi narzędziami (np. Excelem).
- **Klucz jest w tzw. 3V - Volume, Velocity, Variety (później doszły kolejne).**

Volume

Skala (ilość) danych: Gigabajty to za mało. Mówimy o terabajtach, petabajtach, eksabajtach - przykład YouTube

Inne przykłady:

- **Facebook** codziennie generuje 500+ terabajtów nowych danych.
- **CERN (Wielki Zderzacz Hadronów)** generuje 90 petabajtów rocznie.
- Jeden **samolot** pasażerski generuje 2,5 terabajta danych podczas jednego lotu (z czujników).

- **Liczba filmów:** Szacuje się, że YouTube hostuje ponad 5 miliardów filmów.
- **Przyrost danych:** Każdej minuty użytkownicy przesyłają ponad 500 godzin wideo, co daje ponad **720 000** godzin nowych treści dziennie.
- **Zapotrzebowanie na pamięć:** Ten przyrost oznacza, że YouTube musi przechowywać setki petabajtów (PB) nowych danych rocznie.
- **Skala infrastruktury:** Aby obsłużyć ten ruch, YouTube korzysta z centrów danych o pojemności przekraczającej **2500** petabajtów (czyli ponad 2,5 EB) w samej pamięci masowej.

Velocity

Dane napływają strumieniowo, w czasie rzeczywistym. Trzeba je przetwarzać na bieżąco.

- **Transakcje kartą kredytową:** miliony transakcji na minutę.
- **Twitter:** około 6 000 tweetów na sekundę.
- **Czujniki IoT (Internet Rzeczy) w fabryce** – ciągły monitoring**.**

Variety

Różne rodzaje danych - generowane i przetwarzane dosłownie na każdym kroku

- **Dane ustrukturyzowane:** Tabele, bazy danych, Excel (tylko 20% świata danych!).
- **Dane nieustrukturyzowane:** (Reszta - 80%!)
- **Tekst** (emaile, posty, dokumenty)
- **Multimedia** (zdjęcia, filmy, nagrania audio)
- **Dane z czujników** (lokalizacje GPS, odczyty temperatury)

Rozszerzenie - 5V

Veracity, Value

- **Do 3V często dodaje się kolejne:**
- **4. Prawdziwość (Veracity):** Czy dane są wiarygodne? Czyste? Bez błędów? (Garbage In, Garbage Out!)
- **5. Wartość (Value):** Jak wydobyć z tych danych biznesową korzyść? Same dane nic nie znaczą bez analizy.

Netflix – Jak Big Data tworzy hit?

House of Cards (2013) to ogromna, ryzykowna inwestycja o wartości ponad 100 milionów dolarów, która przekształciła Netflix w potęgę streamingu, przyczyniając się do pozyskania ponad 17 milionów nowych abonentów i po raz pierwszy w pierwszym kwartale 2013 roku generując przychody przekraczające 1 miliard dolarów kwartalnie. Serial umocnił oryginalną strategię Netflixa w zakresie treści, działając jako kluczowy czynnik długoterminowego wzrostu i wyceny rynkowej, a nie tylko bezpośredni, natychmiastowy zysk.

Netflix nie kupił "House of Cards" na podstawie przypadku.

Zrobił to na podstawie danych:

- **Volume:** Analizowano miliardy odtworzeń.
- **Variety:** Kto oglądał filmy z reżyserem Finchem? Kto oglądał filmy z Kevinem Spacey? Kto oglądał oryginalną brytyjską wersję?
- **Value:** Skrzyżowanie tych danych pokazało, że istnieje ogromna, niewykorzystana grupa widzów.
- **Wniosek:** Big Data przewidziało sukces, zanim ktokolwiek nakręcił pierwszy odcinek.

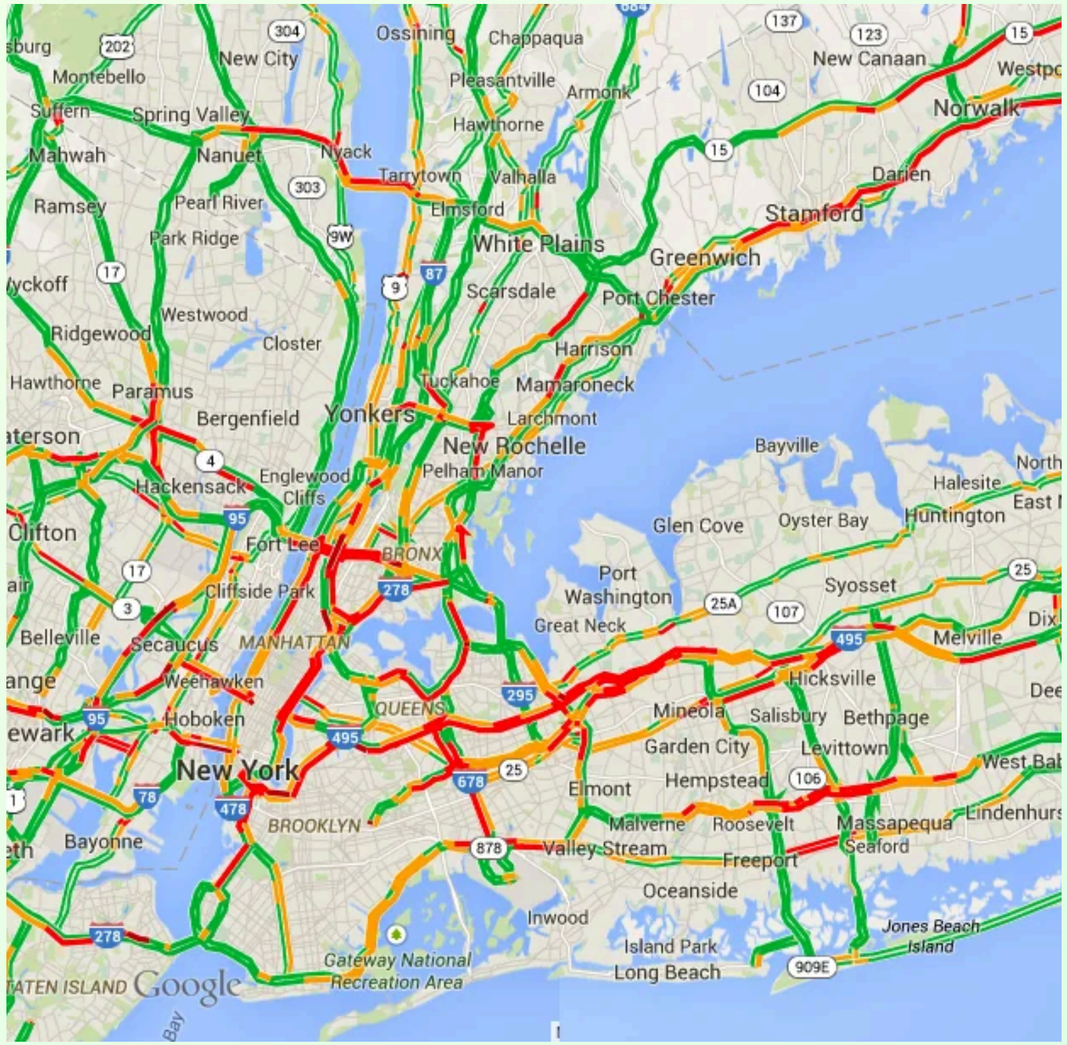

Google Maps – Nawigacja w czasie rzeczywistym

Skąd Google wie, że jest korek?

- **Velocity:** Miliony telefonów z włączoną lokalizacją wysyłają dane w czasie rzeczywistym.
- **Volume:** Analiza tysięcy pojazdów na danym odcinku.
- **Value:** Jeśli wszyscy zwalniają do 5 km/h – to korek. Aplikacja natychmiast proponuje objazd.

Skąd się to wzięło?

Dlaczego Big Data pojawiło się teraz, a nie 50 lat temu?

1. **Sensoryfikacja:** Wszystko ma czujniki (telefony, samochody, lodówki, zegarki).
2. **Tańszy storage:** Przechowywanie 1GB danych kiedyś kosztowało fortunę, dziś to grosze.
3. **Moc obliczeniowa (Cloud):** Przetwarzanie ogromnych danych w chmurze (AWS, Google Cloud, Azure).
4. **Internet:** Łączność globalna, social media, e-commerce.

Skąd się to wzięło?

Dlaczego Big Data pojawiło się teraz, a nie 50 lat temu?

1. **Sensoryfikacja:** Wszystko ma czujniki (telefony, samochody, lodówki, zegarki).
2. **Tańszy storage:** Przechowywanie 1GB danych kiedyś kosztowało fortunę, dziś to grosze.
3. **Moc obliczeniowa (Cloud):** Przetwarzanie ogromnych danych w chmurze (AWS, Google Cloud, Azure).
4. **Internet:** Łączność globalna, social media, e-commerce.

Od Statystyki do Big Data do AI

- **Statystyka (klasyczna):** "Mam małą próbkę. Jak bardzo mogę się mylić?"
- **Big Data:** "Mam wszystkie dane. Nie potrzebuję próbki – widzę cały obraz!"
- **AI/ML:** "Mam wszystkie dane. Niech komputer sam znajdzie w nich zależności i przewidzi przyszłość."

Ciemna strona Big Data

Big Data to nie tylko korzyści. To także wyzwania:

- **Prywatność:** Kto ma prawo do naszych danych?
- **Bezpieczeństwo:** Wycieki danych (coraz częstsze).
- **Etyka:** Czy algorytm podejmujący decyzje na podstawie danych jest sprawiedliwy? (Dyskryminacja w danych treningowych).
- **Szum:** Więcej danych = więcej szumów. Łatwiej znaleźć fałszywe korelacje.

Dyskusja

- **Pytanie 1: Wolność czy zagrożenie?**

"Często słyszymy: 'Big Data to wielka szansa dla medycyny' i jednocześnie 'Big Data to zagrożenie dla prywatności'.' Czy da się to pogodzić? Czy oddalibyście dostęp do anonimowych danych o swoim zdrowiu, by przyspieszyć znalezienie leku na raka?"

- **Pytanie 2: Czy więcej danych = prawda?**

"Jeśli mamy dostęp do wszystkich danych (Volume), to czy nadal potrzebujemy statystyki? Czy Big Data nie zabija wnioskowania statystycznego, skoro mamy 'cały obraz?"

- **Pytanie 3: Algorytm, który cię ocenia**

"Bank ocenia zdolność kredytową nie na podstawie rozmowy z doradcą, ale algorytmu, który przeanalizował miliony transakcji. Algorytm odmawia kredytu, bo “zachowanie zakupowe jest podobne do osób, które nie spłacały długów”. Czy to sprawiedliwe?

Dziękuję za uwagę ;)

Pytania?